Tarea 2: Clasificador bayesiano ingenuo

Saul Ivan Rivas Vega

Aprendizaje Automatizado 9 de marzo de 2020

1. Géneros

Un programa de salud gubernamental desea clasificar los registros de las personas en géneros femenino (F) o masculino (M) a partir de los atributos nombre, estatura y peso. Se cuentan con los siguientes registros:

Nombre	Estatura (m)	Peso (Kg)	Género
Denis	1.72	75.3	M
Guadalupe	1.82	81.6	M
Alex	1.80	86.1	M
Alex	1.70	77.1	M
Cris	1.73	78.2	M
Juan	1.80	74.8	M
Juan	1.80	74.3	M
Denis	1.50	50.5	F
Alex	1.52	45.3	F
Cris	1.62	61.2	F
Rene	1.67	68.0	F
Guadalupe	1.65	58.9	\mathbf{F}
Guadalupe	1.75	68.0	F

Entrena un clasificador bayesiano ingenuo usando estimación por máxima verosimilitud y otro usando estimación por máximo a posteriori. Reporta los parámetros que obtuviste en ambos casos y usa los clasificadores entrenados para predecir la clase de los siguientes vectores: x1 = (Rene, 1.68, 65), x2 = (Guadalupe, 1.75, 80), x3 = (Denis, 1.80, 79), x4 = (Alex, 190, 85) y x5 = (Cris, 165, 70). Describe de forma detallada el procedimiento que seguiste tanto en el entrenamiento como en la predicción y discute los resultados obtenidos. Para el entrenamiento del clasificador por máximo a posteriori considera los siguientes valores para las distribuciones correspondientes:

Género	Nombre	Estatura		Peso			
	α_k	μ_0	σ_0^2	σ^2	μ_0	σ_0^2	σ^2
M	$1, \forall k$	1.7	0.3	0.0020	85.5	17.0	15.76
\mathbf{F}	$1, \forall k$	1.5	0.1	0.0074	70.3	85.0	71.00

1.1. Estimador por máxima verosimilitud

Los atributos son: nombre, estatura y peso, y la clase es género.

1.1.1. Atributo Nombre

Para el nombre podemos asumir una distribución categórica:

$$X_{nombre}^{(i)} \sim Cat(X_{nombre}^{(i)}; q) \tag{1}$$

Donde las categorías son los nombres y los podemos enumerar: Denis - 1, Guadalupe - 2, Alex - 3, Cris - 4, Juan - 5, Rene - 6.

Y así con los nombres de 1 a 6 podemos definir a $Cat(X_{nombre}^{(i)};q)$ como:

$$Cat(X_{nombre}^{(i)}; q) = \prod_{k=1}^{6} q_k^{[x_{nombre}^{(i)} = k]}$$
 (2)

Donde podemos estimar a q_k usando el estimador de máxima verosimilitud como:

$$\hat{q}_k = \frac{c_k}{n}$$
Donde c_k :
$$c_k = \sum_{i=1}^n \left[x_{nombre}^{(i)} = k \right]$$
(3)

Así podemos estimar el parámetro para la primer categoría:

Para la clase **Femenino**:

Y de la misma forma para las categorías restantes:

$$c_{2F} = 2, \ \hat{q}_{(2|F)} = \frac{2}{6}, \ c_{2M} = 1, \ \hat{q}_{(2|M)} = \frac{1}{7}$$

$$c_{3F} = 1, \ \hat{q}_{(3|F)} = \frac{1}{6}, \ c_{3M} = 2, \ \hat{q}_{(3|M)} = \frac{2}{7}$$

$$c_{4F} = 1, \ \hat{q}_{(4|F)} = \frac{1}{6}, \ c_{4M} = 1, \ \hat{q}_{(4|M)} = \frac{1}{7}$$

$$c_{5F} = 0, \ \hat{q}_{(5|F)} = \frac{0}{6} = 0, \ c_{5M} = 2, \ \hat{q}_{(5|M)} = \frac{2}{7}$$

$$c_{6F} = 1, \ \hat{q}_{(6|F)} = \frac{1}{6}, \ c_{6M} = 0, \ \hat{q}_{(6|M)} = \frac{0}{7} = 0$$

$$(5)$$

1.1.2. Atributo Estatura

Para la estatura podemos asumir una distribución normal:

$$X_{estatura}^{(i)} \sim \mathcal{N}(X_{estatura}^{(i)}; \mu; \sigma^2)$$
 (6)

Donde $\mathcal{N}(X_{estatura}^{(i)}; \mu; \sigma^2)$ se define como:

$$\mathcal{N}(X_{estatura}^{(i)}; \mu; \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x^{(i)} - \mu)^2}{2\sigma^2}}$$
(7)

Donde podemos estimar a μ y a σ usando el estimador de máxima verosimilitud como:

Para la clase **Femenino**:

$$\hat{\mu}_F = \frac{1}{n} \sum_{i=1}^n x_{estatura}^{(i)}$$

$$= \frac{1}{6} (1.50 + 1.52 + 1.62 + 1.67 + 1.65 + 1.75)$$

$$= \frac{1}{6} (9.71)$$

$$= 1.618\overline{3}$$
(8)

$$\hat{\sigma}_F^2 = \frac{1}{n} \sum_{i=1}^n (x_{estatura}^{(i)} - \hat{\mu})^2$$

$$= \frac{1}{6} [(1.50 - 1.618\bar{3})^2 + (1.52 - 1.618\bar{3})^2 + \dots + (1.75 - 1.618\bar{3})^2)]$$

$$= \frac{1}{6} [0.014003 + 0.009669 + 0.000002\bar{7} + \dots + 0.0173361111]$$

$$= \frac{1}{6} [0.04468\bar{3}]$$

$$= 0.007447\bar{2}$$
(9)

Para la clase Masculino:

$$\hat{\mu}_{M} = \frac{1}{n} \sum_{i=1}^{n} x_{estatura}^{(i)}$$

$$= \frac{1}{7} (1.72 + 1.82 + 1.80 + 1.70 + 1.73 + 1.80 + 1.80)$$

$$= \frac{1}{7} (12.37)$$

$$= 1.7671428571428571$$
(10)

$$\hat{\sigma}_{M}^{2} = \frac{1}{n} \sum_{i=1}^{n} (x_{estatura}^{(i)} - \hat{\mu})^{2}$$

$$= \frac{1}{7} [(1.72 - 1.76714)^{2} + (1.82 - 1.76714)^{2} + \dots + (1.80 - 1.76714)^{2})]$$

$$= \frac{1}{7} [0.00222245 + 0.00279388 + 0.00107959 + \dots + 0.00107959]$$

$$= \frac{1}{7} [0.014142857142857169]$$

$$= 0.0020204081632653097$$
(11)

1.1.3. Atributo Peso

Para el **peso** podemos asumir una distribución normal:

$$X_{peso}^{(i)} \sim \mathcal{N}(X_{peso}^{(i)}; \mu; \sigma^2) \tag{12}$$

Donde $\mathcal{N}(X_{peso}^{(i)}; \mu; \sigma^2)$ se define como:

$$\mathcal{N}(X_{peso}^{(i)}; \mu; \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x^{(i)} - \mu)^2}{2\sigma^2}}$$
(13)

Donde podemos estimar a μ y a σ usando el estimador de máxima verosimilitud como:

Para la clase Femenino:

$$\hat{\mu}_F = \frac{1}{n} \sum_{i=1}^n x_{peso}^{(i)}$$

$$= \frac{1}{6} (50.5 + 45.3 + 61.2 + 68.0 + 58.9 + 68.0)$$

$$= \frac{1}{6} (351.9)$$

$$= 58.65$$
(14)

$$\hat{\sigma}_F^2 = \frac{1}{n} \sum_{i=1}^n (x_{peso}^{(i)} - \hat{\mu})^2$$

$$= \frac{1}{6} [(50.5 - 58.65)^2 + (45.3 - 58.65)^2 + \dots + (68.0 - 58.65)^2)]$$

$$= \frac{1}{6} [66.42250 + 178.2225 + 6.502500 + \dots + 87.42250]$$

$$= \frac{1}{6} [426.055]$$

$$= 71.00916\overline{7}$$
(15)

$$\hat{\mu}_{M} = \frac{1}{n} \sum_{i=1}^{n} x_{peso}^{(i)}$$

$$= \frac{1}{7} (75.3 + 81.6 + 86.1 + 77.1 + 78.2 + 74.8 + 74.3)$$

$$= \frac{1}{7} (547.4)$$

$$= 78.2$$
(16)

$$\hat{\sigma}_{M}^{2} = \frac{1}{n} \sum_{i=1}^{n} (x_{peso}^{(i)} - \hat{\mu})^{2}$$

$$= \frac{1}{7} [(75.3 - 78.2)^{2} + (81.6 - 78.2)^{2} + \dots + (74.3 - 78.2)^{2})]$$

$$= \frac{1}{7} [8.41 + 11.56 + 62.41 + \dots + 15.21]$$

$$= \frac{1}{7} [110.36]$$

$$= 15.7657142857142$$
(17)

1.1.4. Género

Para la clase (Género) podemos asumir una distribución Bernoulli:

$$Y^{(i)} \sim Ber(Y^{(i)}; q) \tag{18}$$

Donde $Ber(Y^{(i)};q)$ se define como:

$$Ber(Y^{(i)};q) = q^{C}(1-q)^{1-C}$$

$$C = [y = \text{clase}]$$
(19)

Donde podemos estimar a q usando el estimador de máxima verosimilitud como:

Para la clase **Femenino**:

$$\hat{q}_F = \frac{N_F}{N}$$

$$= \frac{6}{13}$$
(20)

$$\hat{q}_M = \frac{N_M}{N}$$

$$= \frac{7}{13}$$
(21)

1.1.5. Uso del Estimador por Máxima Verosimilitud

Clasificaremos al vector de entrada con base en la siguiente ecuación:

$$C = \max \arg_{C \in \{F,M\}} \{P(X|C)P(C)\}$$

Donde las probabilidades de cada parametro al ser independientes se multiplicaran

$$= \max \arg_{C \in \{F,M\}} \{P(C)P(X_{nombre}|C)P(X_{estatura}|C)P(X_{peso}|C)\}$$
(22)

Prueba 1: x1 = (Rene, 1.68, 65)

Probabilidad de que sea Femenino:

$$P(F|x1) \propto P(F) \times P(x1_{nombre}|F) \times P(x1_{estatura}|F) \times P(x1_{peso}|F)$$

$$\propto (\frac{6}{13}) \times (\frac{1}{6}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura}^2}}^2 e^{\frac{-(x1-\hat{\mu}_{estatura}|F)^2}{2\hat{\sigma}_{estatura}^2}}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2}} e^{\frac{-(x1-\hat{\mu}_{peso}|F)^2}{2\hat{\sigma}_{peso}^2}})$$

$$\propto (\frac{6}{13}) \times (\frac{1}{6}) \times (3.4113057085685545) \times (0.03411194570280468)$$

$$\propto 0.00895125193125832$$

$$\propto 0.89512 \%$$
(23)

Probabilidad de que sea Masculino:

$$P(M|x1) \propto P(M) \times P(x1_{nombre}|M) \times P(x1_{estatura}|M) \times P(x1_{peso}|M)$$

$$\propto (\frac{7}{13}) \times (0) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura}^2 M}} e^{\frac{-(x1-\hat{\mu}_{estatura}|M)^2}{2\hat{\sigma}_{estatura}^2}}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2 M}} e^{\frac{-(x1-\hat{\mu}_{peso}|M)^2}{2\hat{\sigma}_{peso}^2 M}})$$

$$\propto (\frac{7}{13}) \times (0) \times (1.641140586274889) \times (0.03411194570280468)$$

$$\propto 0$$

$$\propto 0$$

$$\propto 0 \%$$
(24)

Así para el caso 1 la clasificación sería **Femenino** puesto que $0.89512\,\% > 0\,\%$.

Prueba 2: x2= (Guadalupe, 1.75, 80)

Probabilidad de que sea **Femenino**:

$$P(F|x2) \propto P(F) \times P(x2_{nombre}|F) \times P(x2_{estatura}|F) \times P(x2_{peso}|F)$$

$$\propto (\frac{6}{13}) \times (\frac{2}{6}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura}^2}} e^{\frac{-(x^2 - \hat{\mu}_{estatura}|F)^2}{2\hat{\sigma}_{estatura}^2}}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2}} e^{\frac{-(x^2 - \hat{\mu}_{peso}|F)^2}{2\hat{\sigma}_{peso}^2}})$$

$$\propto (\frac{6}{13}) \times (\frac{2}{6}) \times (1.599858146833577) \times (0.0029789834817996216)$$

$$\propto 0.0007332232296368892$$

$$\propto 0.073322\%$$
(25)

Probabilidad de que sea Masculino:

$$P(M|x2) \propto P(M) \times P(x2_{nombre}|M) \times P(x2_{estatura}|M) \times P(x2_{peso}|M)$$

$$\propto (\frac{7}{13}) \times (\frac{1}{7}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura}^2 M}} e^{\frac{-(x^2 - \hat{\mu}_{estatura}|M)^2}{2\hat{\sigma}_{estatura}^2}}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2 M}} e^{\frac{-(x^2 - \hat{\mu}_{peso}|M)^2}{2\hat{\sigma}_{peso}^2 M}})$$

$$\propto (\frac{7}{13}) \times (\frac{1}{7}) \times (7.720478376796198) \times (0.0029789834817996216)$$

$$\propto 0.050585966030299065$$

$$\propto 5.05859 \%$$
(26)

Así para el caso 2 la clasificación sería **Masculino** puesto que $5.05859\,\% > 0.073322\,\%$.

Prueba 3: x3= (Denis, 1.80, 79)

Probabilidad de que sea **Femenino**:

$$P(F|x3) \propto P(F) \times P(x3_{nombre}|F) \times P(x3_{estatura}|F) \times P(x3_{peso}|F)$$

$$\propto (\frac{6}{13}) \times (\frac{1}{6}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura}^2|F}}^2) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2|F}}^2) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2|F}}^2)$$

$$\propto (\frac{6}{13}) \times (\frac{1}{6}) \times (0.6658947606886298) \times (0.003804820622723802)$$

$$\propto 0.00019489308600244848$$

$$\propto 0.019489\%$$
(27)

Probabilidad de que sea Masculino:

$$P(M|x3) \propto P(M) \times P(x3_{nombre}|M) \times P(x3_{estatura}|M) \times P(x3_{peso}|M)$$

$$\propto (\frac{7}{13}) \times (\frac{1}{7}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura}^2|M}} e^{\frac{-(x3-\hat{\mu}_{estatura}|M)^2}{2\hat{\sigma}_{estatura}^2|K}}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2|M}} e^{\frac{-(x3-\hat{\mu}_{peso}|M)^2}{2\hat{\sigma}_{peso}^2|M}})$$

$$\propto (\frac{7}{13}) \times (\frac{1}{7}) \times (6.53524385337116) \times (0.003804820622723802)$$

$$\propto 0.04595604066151125$$

$$\propto 4.5956 \%$$
(28)

Así para el caso 3 la clasificación sería **Masculino** puesto que 4.5956% > 0.019489%.

Prueba 4: x4 = (Alex, 1.90, 85)

Probabilidad de que sea **Femenino**:

$$P(F|x4) \propto P(F) \times P(x4_{nombre}|F) \times P(x4_{estatura}|F) \times P(x4_{peso}|F)$$

$$\propto (\frac{6}{13}) \times (\frac{1}{6}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura}^2}} e^{\frac{-(x4-\hat{\mu}_{estatura}|F)^2}{2\hat{\sigma}_{estatura}^2}}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2}} e^{\frac{-(x4-\hat{\mu}_{peso}|F)^2}{2\hat{\sigma}_{peso}^2}})$$

$$\propto (\frac{6}{13}) \times (\frac{1}{6}) \times (0.04983987374064044) \times (0.0007349997821943831)$$

$$\propto 0.0000028178689495358674$$

$$\propto 0.00028178\%$$
(29)

Probabilidad de que sea Masculino:

$$P(M|x4) \propto P(M) \times P(x4_{nombre}|M) \times P(x4_{estatura}|M) \times P(x4_{peso}|M)$$

$$\propto (\frac{7}{13}) \times (\frac{2}{7}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura}^2|M}} e^{\frac{-(x4-\hat{\mu}_{estatura}|M)^2}{2\hat{\sigma}_{estatura}^2|F}}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2|M}} e^{\frac{-(x4-\hat{\mu}_{peso}|M)^2}{2\hat{\sigma}_{peso}^2|M}})$$

$$\propto (\frac{7}{13}) \times (\frac{2}{7}) \times (0.1943796927071898) \times (0.0007349997821943831)$$

$$\propto 0.0007914420714764275$$

$$\propto 0.079144 \%$$
(30)

Así para el caso 3 la clasificación sería **Masculino** puesto que $0.079144\,\% > 0.00028178\,\%$.

Prueba 5: x5 = (Cris, 1.65, 70)

Probabilidad de que sea **Femenino**:

$$P(F|x5) \propto P(F) \times P(x5_{nombre}|F) \times P(x5_{estatura}|F) \times P(x5_{peso}|F)$$

$$\propto (\frac{6}{13}) \times (\frac{1}{6}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura|F}^2}} e^{\frac{-(x5-\hat{\mu}_{estatura|F})^2}{2\hat{\sigma}_{estatura|F}^2}}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso|F}^2}} e^{\frac{-(x5-\hat{\mu}_{peso|F})^2}{2\hat{\sigma}_{peso|F}^2}})$$

$$\propto (\frac{6}{13}) \times (\frac{1}{6}) \times (3.989847809495735) \times (0.020294471017724632)$$

$$\propto 0.006228603902687947$$

$$\propto 0.62286 \%$$
(31)

Probabilidad de que sea **Masculino**:

$$P(M|x5) \propto P(M) \times P(x5_{nombre}|M) \times P(x5_{estatura}|M) \times P(x5_{peso}|M)$$

$$\propto (\frac{7}{13}) \times (\frac{1}{7}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{estatura}^2|M}} e^{\frac{-(x5-\hat{\mu}_{estatura}|M)^2}{2\hat{\sigma}_{estatura}^2|F}}) \times (\frac{1}{\sqrt{2\pi\hat{\sigma}_{peso}^2|M}} e^{\frac{-(x5-\hat{\mu}_{peso}|M)^2}{2\hat{\sigma}_{peso}^2|M}})$$

$$\propto (\frac{7}{13}) \times (\frac{1}{7}) \times (0.4472629865983849) \times (0.020294471017724632)$$

$$\propto 0.0005144939695681998$$

$$\propto 0.051449 \%$$
(32)

Así para el caso 3 la clasificación sería **Femenino** puesto que $0.62286\,\% > 0.051449\,\%$.

1.2. Estimador por máximo a posteriori

Los atributos son: nombre, estatura y peso, y la clase es género.

1.2.1. Atributo Nombre

Para el **nombre** podemos asumir una distribución categórica:

$$X_{nombre}^{(i)} \sim Cat(X_{nombre}^{(i)}; q) \tag{33}$$

Donde las categorías son los nombres y los podemos enumerar: Denis - 1, Guadalupe - 2, Alex - 3, Cris - 4, Juan - 5, Rene - 6. Y así con los nombres de 1 a 6 podemos definir a $Cat(X_{nombre}^{(i)};q)$ como:

$$Cat(X_{nombre}^{(i)}; q) = \prod_{k=1}^{6} q_k^{[x_{nombre}^{(i)} = k]}$$
 (34)

Donde podemos estimar a q_k usando el estimador MAP como:

$$\hat{q}_k = \frac{c_k + \alpha_k - 1}{n - K + \sum_{i=1}^K \alpha_i}$$

Donde:

$$\alpha_k = 1, \ \forall k$$

$$K = 6 \tag{35}$$

n = numero elementos de la clase

$$c_k = \sum_{i=1}^{n} \left[x_{nombre}^{(i)} = k \right]$$

Así podemos estimar el parámetro para la primer categoría:

Para la clase **Femenino**:

Y de la misma forma para las categorías restantes:

$$c_{2F} = 2, \ \hat{q}_{(2|F)} = \frac{2}{6}, \ c_{2M} = 1, \ \hat{q}_{(2|M)} = \frac{1}{7}$$

$$c_{3F} = 1, \ \hat{q}_{(3|F)} = \frac{1}{6}, \ c_{3M} = 2, \ \hat{q}_{(3|M)} = \frac{2}{7}$$

$$c_{4F} = 1, \ \hat{q}_{(4|F)} = \frac{1}{6}, \ c_{4M} = 1, \ \hat{q}_{(4|M)} = \frac{1}{7}$$

$$c_{5F} = 0, \ \hat{q}_{(5|F)} = \frac{0}{6} = 0, \ c_{5M} = 2, \ \hat{q}_{(5|M)} = \frac{2}{7}$$

$$c_{6F} = 1, \ \hat{q}_{(6|F)} = \frac{1}{6}, \ c_{6M} = 0, \ \hat{q}_{(6|M)} = \frac{0}{7} = 0$$

$$(37)$$

2. Spam